

VINÍCIUS DE LIMA GONÇALVES

MODELOS DE LINGUAGEM PEQUENOS COM E SEM RECUPERAÇÃO AUMENTADA
PARA PERGUNTAS SOBRE BULAS DE MEDICAMENTOS

(versão pré-defesa, compilada em 1 de julho de 2026)

Documento apresentado como requisito parcial ao exame de qualificação de Mestrado no Programa de Pós-Graduação em Informática, Setor de Ciências Exatas, da Universidade Federal do Paraná.

Área de concentração: *Computação*.

Orientador: Orientador a confirmar.

CURITIBA

2026

RESUMO

De acordo com o item 4.1.2 da NBR 6028:2021, o resumo deve ser composto por uma sequência de frases concisas em um único parágrafo, que deve caber em uma única página. O resumo deve ser informativo, ou seja, deve ser a condensação do conteúdo, expondo finalidades, metodologia, resultados e conclusões.

Palavras-chave: Modelos de linguagem; recuperação aumentada por geração; bulas de medicamentos; avaliação de sistemas.

ABSTRACT

O *abstract* deve ser a tradução em inglês do resumo e deve seguir as mesmas regras deste.

Keywords: Language models; retrieval-augmented generation; drug leaflets; system evaluation.

LISTA DE FIGURAS

LISTA DE TABELAS

LISTA DE ABREVIATURAS E SIGLAS

DINF	Departamento de Informática
PPGINF	Programa de Pós-Graduação em Informática
UFPR	Universidade Federal do Paraná

LISTA DE SÍMBOLOS

α	alfa, primeira letra do alfabeto grego
β	beta, segunda letra do alfabeto grego
γ	gama, terceira letra do alfabeto grego
ω	ômega, última letra do alfabeto grego
π	pi
τ	Tempo de resposta do sistema
θ	Ângulo de incidência do raio luminoso

SUMÁRIO

1	INTRODUÇÃO	11
1.1	CONTEXTO E MOTIVAÇÃO	11
1.2	PROBLEMA DE PESQUISA	11
1.3	PERGUNTAS DE PESQUISA	11
1.4	HIPÓTESE	11
1.5	OBJETIVOS	11
1.5.1	Objetivo Geral.	11
1.5.2	Objetivos Específicos	11
1.6	CONTRIBUIÇÕES ESPERADAS	11
1.7	DELIMITAÇÃO E ESCOPO	11
1.8	ORGANIZAÇÃO DO DOCUMENTO	11
2	FUNDAMENTAÇÃO TEÓRICA.	12
2.1	BULAS DE MEDICAMENTOS NO BRASIL.	12
2.1.1	Estrutura e Exigências da ANVISA.	12
2.1.2	Protocolos, Resoluções e Orientações Oficiais	12
2.2	MODELOS DE LINGUAGEM.	12
2.2.1	Arquitetura Transformer	12
2.2.2	Modelos de Grande e Pequeno Porte	12
2.2.3	Português Brasileiro e Terminologia Médico-Farmacêutica	12
2.2.4	Tokenização e Representação de Termos Especializados.	12
2.2.5	Execução Local, Quantização e Eficiência Computacional.	12
2.2.6	Privacidade e Soberania Tecnológica	12
2.3	GERAÇÃO AUMENTADA POR RECUPERAÇÃO (RAG).	12
2.3.1	Pipeline RAG	12
2.3.2	Representação Vetorial e Indexação	12
2.4	AVALIAÇÃO DE SISTEMAS DE PERGUNTA E RESPOSTA.	12
2.4.1	Factualidade, Grounding, Segurança e Utilidade	12
2.4.2	Métricas Léxicas	12
2.4.3	Métricas Semânticas	12
2.4.4	Métricas de RAG	12
2.4.5	Avaliação Humana e Taxonomias de Erro	12
3	TRABALHOS RELACIONADOS	13
3.1	MODELOS DE LINGUAGEM EM SAÚDE.	13
3.2	MODELOS PEQUENOS E EFICIENTES EM SAÚDE.	13
3.3	PLN BIOMÉDICO E FARMACÊUTICO EM PORTUGUÊS BRASILEIRO. . .	13

3.4	RAG EM DOMÍNIO BIOMÉDICO E FARMACÊUTICO	13
3.5	SISTEMAS BASEADOS EM BULAS E DOCUMENTOS REGULATÓRIOS .	13
3.6	AVALIAÇÃO DE SISTEMAS DE PERGUNTA E RESPOSTA EM SAÚDE. . .	13
3.7	FACTUALIDADE E SEGURANÇA EM INFORMAÇÕES SOBRE MEDICA- MENTOS	13
3.8	SÍNTESE COMPARATIVA E POSICIONAMENTO DO DRUGSLM	13
3.9	CONSIDERAÇÕES DO CAPÍTULO	13
4	METODOLOGIA	14
4.1	DESENHO DA PESQUISA	15
4.2	VISÃO GERAL DO PIPELINE	15
4.3	CORPUS: BULAS DA ANVISA.	15
4.3.1	CrITÉRIOS DE SELEÇÃO.	15
4.3.2	Bula do Paciente e Bula do Profissional	15
4.4	FONTES NORMATIVAS OFICIAIS	15
4.4.1	CrITÉRIOS DE SELEÇÃO, VIGÊNCIA E VERSIONAMENTO	15
4.4.2	Separação entre Bulas e Fontes Normativas	15
4.5	PROCESSAMENTO DO CORPUS	15
4.5.1	Extração e Limpeza de Texto	15
4.5.2	Segmentação de Seções e Metadados.	15
4.5.3	Proveniência e Controle de Versões.	15
4.5.4	Análise de Tokenização	15
4.6	CONSTRUÇÃO DO BANCO VETORIAL	15
4.6.1	Geração de Embeddings	15
4.6.2	Indexação e Recuperação	15
4.7	DATASET DE AVALIAÇÃO.	15
4.7.1	Dataset Sintético	15
4.7.2	Templates, Perfis de Usuário e Níveis de Risco	15
4.7.3	Perguntas Humanas e Validação Adicional.	15
4.8	PADRÃO DE REFERÊNCIA SINTÉTICO	15
4.8.1	Geração Independente por Codex e Claude.	15
4.8.2	Revisão Cruzada e Tratamento de Divergências	15
4.9	CONFIGURAÇÃO EXPERIMENTAL.	15
4.9.1	Modelos Llama e Condições com e sem RAG	15
4.9.2	Condições Experimentais de Segurança	15
4.10	PROTOCOLO DE AVALIAÇÃO.	15
4.10.1	Factualidade Baseada em Evidências	15
4.10.2	Segurança, Utilidade e Adequação da Resposta	15
4.10.3	Qualidade da Recuperação	15
4.10.4	Falhas de Recuperação e Falhas de Geração	15

4.10.5	Análise e Gravidade dos Erros	15
4.11	AMBIENTE COMPUTACIONAL E REPRODUTIBILIDADE	15
4.11.1	Hardware, Quantização, Memória e Latência	15
4.11.2	Registro de Configurações e Execuções	15
4.12	VALIDAÇÃO HUMANA E ASPECTOS ÉTICOS.	15
4.13	CONSIDERAÇÕES DO CAPÍTULO	15
5	RESULTADOS PRELIMINARES	16
5.1	PILOTO: TRÊS PRINCÍPIOS ATIVOS	16
5.1.1	Seleção dos Documentos	16
5.1.2	Validação do Pipeline Ponta a Ponta	16
5.2	CARACTERIZAÇÃO DO CORPUS E DO DATASET	16
5.3	QUALIDADE DA RECUPERAÇÃO.	16
5.4	ANÁLISE COMPARATIVA	16
5.4.1	Comparação Léxica	16
5.4.2	Comparação Semântica	16
5.4.3	Avaliação do RAG	16
5.5	FACTUALIDADE, SEGURANÇA E UTILIDADE	16
5.6	ANÁLISE POR PERFIL, COMPLEXIDADE E RISCO.	16
5.7	ANÁLISE DE ERROS	16
5.8	DESEMPENHO COMPUTACIONAL	16
5.9	CONSIDERAÇÕES DO CAPÍTULO	16
6	CONSIDERAÇÕES FINAIS	17
6.1	SÍNTESE DA PROPOSTA	17
6.2	ALCANCE DAS EVIDÊNCIAS OBTIDAS	17
6.3	LIMITAÇÕES E AMEAÇAS À VALIDADE	17
6.4	TRABALHOS FUTUROS	17
6.5	CRONOGRAMA	17
	REFERÊNCIAS	18

1 INTRODUÇÃO

1.1 CONTEXTO E MOTIVAÇÃO

1.2 PROBLEMA DE PESQUISA

1.3 PERGUNTAS DE PESQUISA

1.4 HIPÓTESE

1.5 OBJETIVOS

1.5.1 Objetivo Geral

1.5.2 Objetivos Específicos

1.6 CONTRIBUIÇÕES ESPERADAS

1.7 DELIMITAÇÃO E ESCOPO

1.8 ORGANIZAÇÃO DO DOCUMENTO

2 FUNDAMENTAÇÃO TEÓRICA

2.1 BULAS DE MEDICAMENTOS NO BRASIL

2.1.1 Estrutura e Exigências da ANVISA

2.1.2 Protocolos, Resoluções e Orientações Oficiais

2.2 MODELOS DE LINGUAGEM

2.2.1 Arquitetura Transformer

2.2.2 Modelos de Grande e Pequeno Porte

2.2.3 Português Brasileiro e Terminologia Médico-Farmacêutica

2.2.4 Tokenização e Representação de Termos Especializados

2.2.5 Execução Local, Quantização e Eficiência Computacional

2.2.6 Privacidade e Soberania Tecnológica

2.3 GERAÇÃO AUMENTADA POR RECUPERAÇÃO (RAG)

2.3.1 Pipeline RAG

2.3.2 Representação Vetorial e Indexação

2.4 AVALIAÇÃO DE SISTEMAS DE PERGUNTA E RESPOSTA

2.4.1 Factualidade, Grounding, Segurança e Utilidade

2.4.2 Métricas Léxicas

2.4.3 Métricas Semânticas

2.4.4 Métricas de RAG

2.4.5 Avaliação Humana e Taxonomias de Erro

3 TRABALHOS RELACIONADOS

3.1 MODELOS DE LINGUAGEM EM SAÚDE

3.2 MODELOS PEQUENOS E EFICIENTES EM SAÚDE

3.3 PLN BIOMÉDICO E FARMACÊUTICO EM PORTUGUÊS BRASILEIRO

3.4 RAG EM DOMÍNIO BIOMÉDICO E FARMACÊUTICO

3.5 SISTEMAS BASEADOS EM BULAS E DOCUMENTOS REGULATÓRIOS

3.6 AVALIAÇÃO DE SISTEMAS DE PERGUNTA E RESPOSTA EM SAÚDE

3.7 FACTUALIDADE E SEGURANÇA EM INFORMAÇÕES SOBRE MEDICAMENTOS

3.8 SÍNTESE COMPARATIVA E POSICIONAMENTO DO DRUGSLM

3.9 CONSIDERAÇÕES DO CAPÍTULO

4 METODOLOGIA

4.1 DESENHO DA PESQUISA

4.2 VISÃO GERAL DO PIPELINE

4.3 CORPUS: BULAS DA ANVISA

4.3.1 Critérios de Seleção

4.3.2 Bula do Paciente e Bula do Profissional

4.4 FONTES NORMATIVAS OFICIAIS

4.4.1 Critérios de Seleção, Vigência e Versionamento

4.4.2 Separação entre Bulas e Fontes Normativas

4.5 PROCESSAMENTO DO CORPUS

4.5.1 Extração e Limpeza de Texto

4.5.2 Segmentação de Seções e Metadados

4.5.3 Proveniência e Controle de Versões

4.5.4 Análise de Tokenização

4.6 CONSTRUÇÃO DO BANCO VETORIAL

4.6.1 Geração de Embeddings

4.6.2 Indexação e Recuperação

4.7 DATASET DE AVALIAÇÃO

4.7.1 Dataset Sintético

4.7.2 Templates, Perfis de Usuário e Níveis de Risco

4.7.3 Perguntas Humanas e Validação Adicional

4.8 PADRÃO DE REFERÊNCIA SINTÉTICO

4.8.1 Geração Independente por Codex e Claude

4.8.2 Revisão Cruzada e Tratamento de Divergências

4.9 CONFIGURAÇÃO EXPERIMENTAL

4.9.1 Modelos Llama e Condições com e sem RAG

4.9.2 Condições Experimentais de Segurança

5 RESULTADOS PRELIMINARES

5.1 PILOTO: TRÊS PRINCÍPIOS ATIVOS

5.1.1 Seleção dos Documentos

5.1.2 Validação do Pipeline Ponta a Ponta

5.2 CARACTERIZAÇÃO DO CORPUS E DO DATASET

5.3 QUALIDADE DA RECUPERAÇÃO

5.4 ANÁLISE COMPARATIVA

5.4.1 Comparação Léxica

5.4.2 Comparação Semântica

5.4.3 Avaliação do RAG

5.5 FACTUALIDADE, SEGURANÇA E UTILIDADE

5.6 ANÁLISE POR PERFIL, COMPLEXIDADE E RISCO

5.7 ANÁLISE DE ERROS

5.8 DESEMPENHO COMPUTACIONAL

5.9 CONSIDERAÇÕES DO CAPÍTULO

6 CONSIDERAÇÕES FINAIS

6.1 SÍNTESE DA PROPOSTA

6.2 ALCANCE DAS EVIDÊNCIAS OBTIDAS

6.3 LIMITAÇÕES E AMEAÇAS À VALIDADE

6.4 TRABALHOS FUTUROS

6.5 CRONOGRAMA

REFERÊNCIAS